

NOMBRES: Benjamín Farías, Benjamín Lepe

N.ALUMNO: 17642531, 17641756



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE  
ESCUELA DE INGENIERÍA  
DEPARTAMENTO DE CIENCIAS DE LA COMPUTACIÓN

IIC3633 — Sistemas Recomendadores — 2' 2021

## Tarea 1: MyAnimeRecSys

### Actividad 1: Exploración de Datos

A partir del dataset de training, generamos gráficos para mostrar la distribución del número de interacciones tanto por usuarios, como por animes. Luego, utilizando estos gráficos realizamos un análisis sobre el comportamiento de dichas densidades. Además, se identificaron los 5 usuarios y animes más activos/populares en términos de sus interacciones, respectivamente.

#### Interacciones por Usuario

A continuación se muestran los 5 usuarios más activos en el dataset:

```
Usuarios más activos:  
user_id  n_interactions  
297988   134  
469      131  
214484   129  
6088     129  
131228   128
```

Figura 1: Usuarios más activos

El porcentaje de las interacciones que han sido hechas por estos 5 usuarios es 0,044 %, lo que parece indicar que la cantidad de animes vistos por usuario en el dataset está considerablemente balanceada. Analizando el gráfico de interacciones por usuario (**figura 2**), se puede observar que los datos parecen seguir una distribución **Normal o Log-Normal**, en donde en promedio los usuarios han visto entre 71 y 78 animes, lo que confirma el balance mencionado anteriormente, y además se puede traducir en que la mayoría de ellos han interactuado con varios ítems, evitando así problemas de *Cold Start* con nuestros algoritmos de recomendación. Este balance se debe muy posiblemente a que la mayoría de usuarios de esta plataforma son consumidores dedicados (es decir, que ven bastante anime), ya que los casuales no requieren de una página para guardar registro de sus animes vistos.




Figura 2: Distribución del número de interacciones por usuario

## Interacciones por Anime

A continuación se muestran los 5 animes más populares en el dataset:

Animes más vistos:

anime_id	Name
1535	Death Note
6547	Angel Beats!
11757	Sword Art Online
16498	Shingeki no Kyojin
19815	No Game No Life

Figura 3: Animes más populares

El porcentaje de las interacciones que han sido realizadas sobre los 5 animes más vistos es 1,008 %. Esto último tiene mucho sentido, ya que ocupan posiciones muy altas dentro del ranking de popularidad de la plataforma [1].




Figura 4: Distribución del número de interacciones por anime

Al analizar el gráfico de interacciones por anime (**figura 4**), se logra apreciar una clara **distribución exponencial**, en donde los animes más populares se encuentran en un pequeño grupo y los menos vistos representan a la otra gran mayoría. Esto suele suceder en medios de entretenimiento masivos (animes, películas, series, videojuegos), ya que la tendencia de las masas suele afectar a la mayoría de usuarios.

### Estadísticas del Dataset de Training

n_users	n_items	avg_animes_by_user	std_animes_by_user	avg_users_by_anime	std_users_by_anime	density (%)	sparsity (%)
18552	2326	79.509217	13.701655	634.159501	513.600988	3.418281	96.581719

Figura 5: Estadísticas del dataset

A partir del *sparsity*, podemos concluir que la proporción de interacciones entre usuarios y animes es bastante baja en comparación con el total posible (tamaño de la matriz). Esto es completamente esperable, ya que la cantidad de animes existentes es enorme, lo que implica que la gran mayoría de usuarios (incluso los fanáticos dedicados) sólo han visto una pequeña porción de estos a lo largo de su vida. Además, se puede ver que la media y la desviación estándar calzan con lo que aparentan sus respectivos gráficos de distribución.

## Actividad 2: Recomendación NO Personalizada

Se implementaron dos métodos de recomendación no personalizada: *Most Popular* y *Random*. Para comparar el rendimiento de estos algoritmos, ambos fueron evaluados con las mismas métricas (nDCG@30 y MAP@30). Además, para tener un resultado más consistente dentro del recomendador Random, se realizaron 3 evaluaciones que posteriormente fueron promediadas, dando los siguientes resultados:

	nDCG@30	MAP@30
<b>Most Popular</b>	0.02162	0.01367
<b>Random</b>	0.00704	0.00301

Cuadro 1: Evaluación de sistemas de recomendación no personalizados

Observando los resultados, claramente el método Most Popular fue el que obtuvo el mejor desempeño tanto en nDCG@30, como en MAP@30. Esto último se debe a que generalmente los ítems que son más populares son conocidos debido a que muchas personas les han dado un buen rating, lo que implica que hay una gran probabilidad de que si escogemos un anime popular, este le gustará a la mayoría de los usuarios. Por otro lado, si se escoge un anime aleatorio en el dataset, existe una gran probabilidad de que sea poco conocido (debido a la distribución exponencial encontrada anteriormente), por lo que es esperable que no haya sido visto por el usuario en el dataset de validación y por lo tanto entregue métricas pobres de rendimiento.

## Actividad 3: Recomendación Basada en Feedback Implícito

En esta parte, se implementaron dos modelos basados en *Matrix Factorization*: **Factorización Matricial optimizada con Alternate Least Squares (ALS)** y **Factorización Matricial optimizada con Bayesian Personalized Ranking (BPR)**.




Figura 6: Desempeño de ALS según el número de factores latentes

Para poder comparar su rendimiento, se realizó un análisis de sensibilidad variando la dimensión de factores latentes de cada modelo.

Dentro del gráfico de desempeño para ALS (**figura 6**), se puede observar que mientras más aumenta el número de factores latentes, el resultado de las métricas de evaluación comienza a empeorar notablemente, de lo que se puede concluir que para este experimento el algoritmo obtiene mejores resultados con un bajo número de factores.




Figura 7: Desempeño de BPR según el número de factores latentes.

Por otro lado, si vemos el gráfico de desempeño para BPR (**figura 7**), podemos observar que no hay un patrón visible sobre el número de factores latentes y su desempeño, por lo tanto, es difícil obtener alguna conclusión al respecto, excepto que para este problema el algoritmo BPR parece no ser tan correcto al momento de modelar las relaciones entre usuarios e ítems (reflejado en rendimiento similar con distinto número de factores latentes).

Luego, si realizamos una comparación entre los dos sistemas recomendadores, el que logra un mejor rendimiento según las métricas utilizadas es el algoritmo ALS, con una mejora de casi el 60 % respecto a BPR.

Modelo / N° de Factores	50	100	200	500	1000
ALS	9.07 s	8.69 s	13.69 s	28.13 s	71.03 s
BPR	13.77 s	16.97 s	20.48 s	39.19 s	71.6 s

Cuadro 2: Tiempos de entrenamiento de cada modelo según el número de factores

Analizando la tabla que muestra los tiempos de entrenamiento (**cuadro 2**), se puede observar que a medida que aumenta el número de factores latentes, el tiempo de entrenamiento también lo hace. Esto se debe a que al tener más factores se tienen más componentes vectoriales que entrenar, lo que a su vez se traduce en un mayor tiempo de ejecución. Luego, comparando la *performance* de los modelos, se puede observar que siempre el modelo ALS tarda menos en entrenar que BPR, lo que se debe a que este último

debe realizar una comparación entre dos ítems para cada uno de los usuarios y luego aprender patrones de preferencia para el usuario, mientras que ALS solamente requiere utilizar un ítem y un usuario para aprender sus preferencias [2]. Esto último explica el poco tiempo observado a diferencia del otro modelo.

## Actividad 4: Recomendación Basada en Contenido

Para esta actividad se trabajó utilizando los embeddings de tipo *Universal Sentence Encoding* de Google, que representan el contenido de cada anime mediante vectores precalculados de 512 dimensiones [3]. Estos vectores fueron reducidos en su dimensionalidad utilizando **PCA (Principal Component Analysis)**, de forma que la recomendación fuese más eficiente. Para implementar el recomendador basado en contenido se tuvo que generar un vector representativo para los gustos de cada usuario, calculado como el promedio de los vectores de cada anime visto por dicho usuario. Finalmente, la recomendación se hace escogiendo aquellos animes (no vistos por el usuario) cuyos vectores sean los más cercanos a los del usuario, considerando distintas métricas de distancia. Para poder comparar el rendimiento, se realizó un análisis de sensibilidad variando la métrica utilizada para la distancia (**coseno, euclidiana, manhattan**), así como las dimensiones de los vectores resultantes tras aplicar PCA.

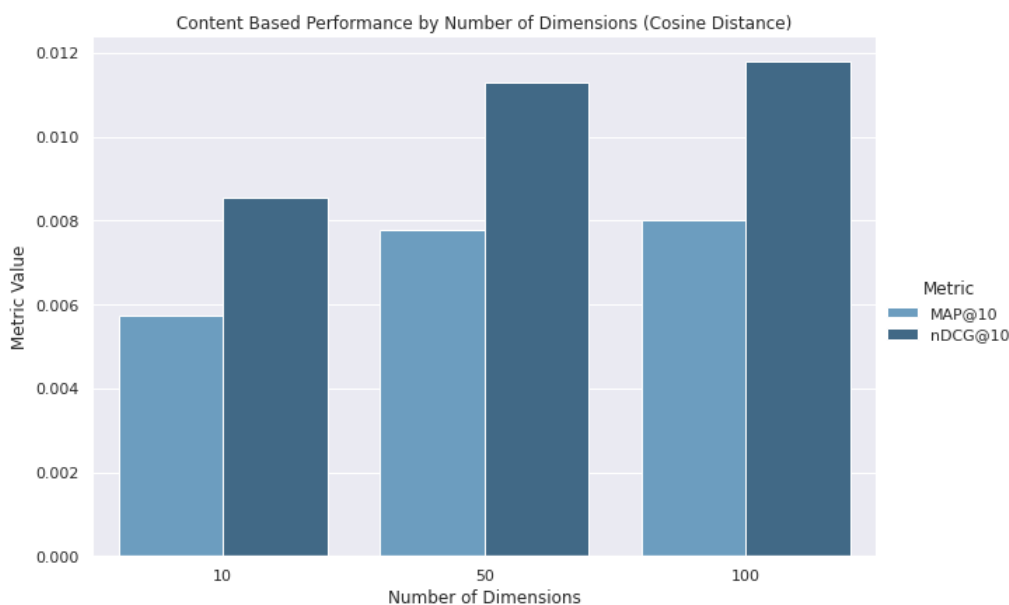


Figura 8: Desempeño según la distancia coseno

Al observar los resultados según la distancia coseno (**figura 8**), se ve que mientras más dimensiones se usan para los vectores, mejor es el rendimiento del recomendador. Esto es esperable, debido a que los vectores fueron generados a partir de las descripciones y contenidos de cada anime, lo que no puede ser representado de forma precisa ocupando sólo unas pocas dimensiones, de lo contrario todos los animes serían muy parecidos entre sí (lo que claramente no es el caso).




Figura 9: Desempeño según la distancia euclidiana

Al ver los resultados según la distancia euclidiana (**figura 9**), se puede apreciar el mismo comportamiento que con la distancia coseno, en donde aumenta el rendimiento junto a la dimensionalidad de los vectores. A pesar de esto, se aprecia un desempeño muy inferior en cuanto a las métricas calculadas. Esto último se puede deber a que la distancia euclidiana asume alguna relación fuerte entre los elementos [4], lo que no es realmente cierto para estos vectores, dado que los originales representaban características desconocidas sobre los contenidos, y además se aplicó PCA, reduciendo las dimensiones a una representación que pasa a ser una caja negra en su totalidad.

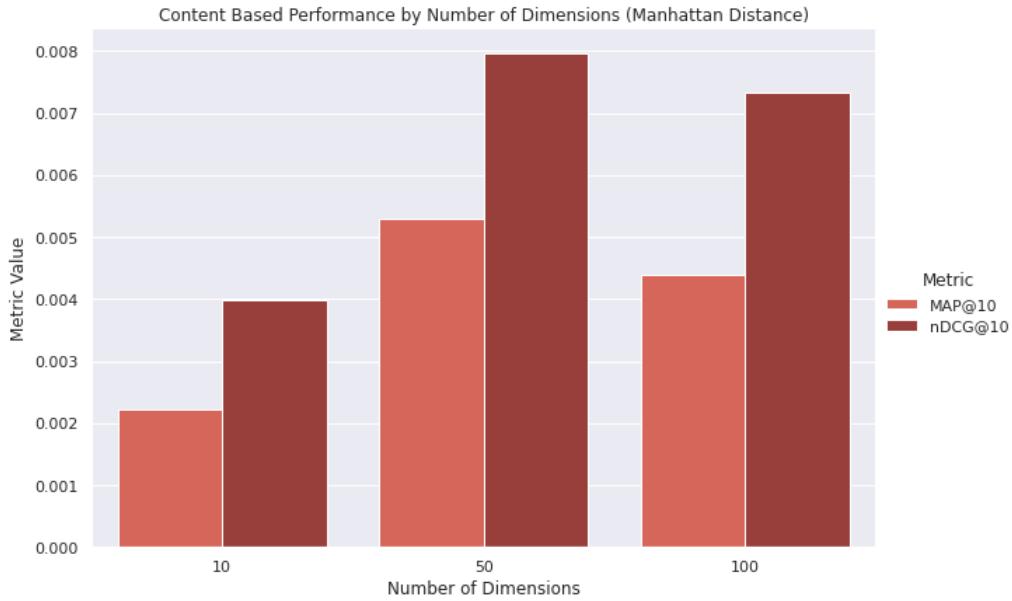


Figura 10: Desempeño según la distancia manhattan

Al analizar los resultados según la distancia manhattan (**figura 10**), ocurre algo inesperado, los vectores con 50 dimensiones se comportan mejor que los de 100, por lo que se podría argumentar que en 50 dimensiones la distancia converge a un máximo local de rendimiento, y que teniendo sólo 10 dimensiones no es suficiente para representar correctamente a los animes, pero con más de 50 la distancia manhattan pierde precisión y también empeora su desempeño.

En resumen, se encontró que **la mejor distancia para este sistema corresponde a la coseno**, que no cae en problemas de precisión ni dependencia de relaciones. En cuanto a la dimensionalidad de los vectores tras aplicar PCA, en general se obtuvo un **mejor rendimiento con 100 dimensiones**, de forma que se pierda menos información valiosa al realizar esta reducción.

## Actividad 5: Comparación de Métodos

Model	nDCG@10	MAP@10	nDCG@20	MAP@20	nDCG@30	MAP@30
Most Popular	0.012204	0.011027	0.017417	0.012846	0.021628	0.013672
Random	0.004309	0.002899	0.005570	0.002986	0.007844	0.003484
ALS (50 Latent Factors)	0.022948	0.014717	0.033700	0.017475	0.042034	0.018983
BPR (50 Latent Factors)	0.016732	0.011146	0.024909	0.013288	0.030534	0.014266
Content Based (PCA@100 + Cosine Distance)	0.011925	0.008347	0.017771	0.009880	0.021820	0.010545

Figura 11: Comparación de los mejores modelos de cada método

Dentro de la tabla (**figura 11**) se puede apreciar que el modelo **Random** fue el que obtuvo los peores resultados en todas las métricas, lo que pensamos que se debe a que el dataset está distribuido de una forma en que la mayor parte de los animes son poco conocidos, y por lo tanto, es muy difícil que aparezcan entre los vistos por los usuarios en el set de validación. Por otro lado, el modelo **Most Popular** logra resultados mucho mejores, puesto que los animes que recomienda suelen ser vistos por la mayoría de usuarios (es decir, es bastante probable que aparezcan en el set de validación de un usuario cualquiera).

Al contrario del modelo antes mencionado, **ALS** fue el que obtuvo el mejor rendimiento en prácticamente todas las métricas, lo que en realidad fue una sorpresa, ya que el dataset de entrenamiento tenía un alto nivel de sparsity ( $\sim 97\%$ ) y, por ende, una baja densidad de datos para poder utilizar en la matriz del entrenamiento. Aún así, la eficiencia del algoritmo superó las expectativas y casi duplicó los valores obtenidos por los demás modelos, lo que nos indica que los animes vistos por cada usuario modelan de forma apropiada sus gustos en general. En cuanto al modelo **BPR**, este tuvo un peor rendimiento que **ALS**, lo que sospechamos se debe a la presencia de muchos animes desconocidos, tales que son considerados como peores por este modelo al compararlos con los que el usuario sí vió. Esto se diferencia del modelo que utiliza **ALS**, donde sólo se consideran los animes vistos por sí solos y no se realizan comparaciones entre pares de estos [2].

Para el caso del modelo basado en contenido (**Content Based**), el resultado obtenido es casi el mismo que el modelo **Most Popular**, lo que creemos que se debe a que el contenido utilizado para la creación del vector de características no posee la información suficiente para realizar una buena recomendación. La razón por la que pensamos que la información no es suficiente, es debido a que una sinopsis si bien puede dar una idea del contenido que tendrá el anime, no necesariamente nos indica que este será igual de bueno que otro, pues ambos pueden tratar sobre lo mismo, pero diferenciarse en la calidad de la producción, desarrollo de la historia y personajes. Esta diferencia hace que animes con temáticas similares puedan resultar en una opinión completamente opuesta de parte del usuario (por ejemplo, que no le agradaron los personajes de un anime, y le encantaron los del otro).



## Actividad 6: Ejemplos de Recomendación de Anime

En esta última parte de la tarea, se analizarán los resultados de nuestro **mejor modelo recomendador (ALS)** sobre 3 usuarios particulares del set de testing. Cabe mencionar que se decidió no desplegar la sinopsis de cada anime en el desarrollo de esta actividad, ya que eran muy extensas y no aportaban mucho valor al análisis (al ser descripciones abiertas sobre la temática de cada anime).

Para nuestro primer usuario (**figura 12**), tenemos que sus gustos se centran en los géneros de la **comedia y lo supernatural**. Cabe destacar que parece ser fan de la franquicia *Monogatari*, ya que ha visto más de una de sus temporadas/versiones. En cuanto a las recomendaciones obtenidas, se observan varias entradas correspondientes a la franquicia *Monogatari*, lo que tiene total sentido según lo destacado anteriormente. Además, aparecen varios animes del género de comedia y supernatural, respaldando la calidad de los resultados.

User ID: 302567  
Previously Watched

anime_id	Name	Genres
268	Golden Boy	Adventure, Comedy, Ecchi
874	Digimon Tamers	Adventure, Comedy, Drama, Fantasy, Shounen
2251	Baccano!	Action, Comedy, Historical, Mystery, Supernatural
5081	Bakemonogatari	Romance, Supernatural, Mystery, Vampire
7785	Yojouhan Shinwa Taikei	Mystery, Comedy, Psychological, Romance
12893	Danshi Koukousei no Nichijou Specials	Comedy, School, Shounen, Slice of Life
28025	Tsukimonogatari	Mystery, Comedy, Supernatural, Ecchi
28701	Fate/stay night: Unlimited Blade Works 2nd Season	Action, Fantasy, Magic, Supernatural
31240	Re:Zero kara Hajimeru Isekai Seikatsu	Psychological, Drama, Thriller, Fantasy
31665	Hibike! Euphonium: Kakedasu Monaka	Drama, Music, School

4

Recommended

anime_id	Name	Genres
17074	Monogatari Series: Second Season	Mystery, Comedy, Supernatural, Romance, Vampire
15689	Nekomonogatari: Kuro	Comedy, Supernatural, Romance, Ecchi
6746	Durarara!!	Action, Mystery, Supernatural
21855	Hanamonogatari	Mystery, Comedy, Supernatural
18679	Kill la Kill	Action, Comedy, Super Power, Ecchi, School
31181	Owarimonogatari	Mystery, Comedy, Supernatural, Vampire
17265	Log Horizon	Action, Game, Adventure, Magic, Fantasy
11741	Fate/Zero 2nd Season	Action, Supernatural, Magic, Fantasy
28223	Death Parade	Game, Mystery, Psychological, Drama, Thriller
1519	Black Lagoon: The Second Barrage	Action, Seinen

Figura 12: Recomendaciones para un usuario interesado en el género de comedia y supernatural

Para nuestro segundo usuario (**figura 13**), tenemos que sus gustos se centran en los géneros del **romance y acción**. Dentro de las recomendaciones entregadas, se pueden encontrar muchos animes de acción, de los que varios tienen temática de demonios y vampiros. Esto puede deberse a que el sistema aprendió que este tipo de temáticas suelen ir de la mano con la acción, drama y romance, fijándose además en que el usuario vio un anime basado en vampiros (*Rosario to Vampire*), y otro basado en demonios (*Kamisama Hajimemashita*).

User ID: 311453

Previously Watched

anime_id	Name	Genres
2476	School Days	Harem, Drama, Romance, School
2993	Rosario to Vampire	Harem, Comedy, Romance, Ecchi, Vampire, Fantasy, School, Shounen
10578	C³	Action, Comedy, Ecchi, School, Supernatural
13601	Psycho-Pass	Action, Sci-Fi, Police, Psychological
14713	Kamisama Hajimemashita	Comedy, Demons, Supernatural, Romance, Fantasy, Shoujo
15583	Date A Live	Sci-Fi, Harem, Comedy, Romance, Mecha, School
27655	Aldnoah.Zero 2nd Season	Action, Mecha, Sci-Fi, Space
27775	Plastic Memories	Sci-Fi, Drama, Romance
31680	Super Lovers	Slice of Life, Comedy, Drama, Romance, Shounen Ai
38671	Enen no Shouboutai	Action, Supernatural, Shounen

Recommended

anime_id	Name	Genres
18153	Kyoukai no Kanata	Slice of Life, Supernatural, Fantasy
9919	Ao no Exorcist	Action, Demons, Fantasy, Shounen, Supernatural
6746	Durarara!!	Action, Mystery, Supernatural
38000	Kimetsu no Yaiba	Action, Demons, Historical, Shounen, Supernatural
14467	K	Action, Mystery, Super Power, Supernatural
18679	Kill la Kill	Action, Comedy, Super Power, Ecchi, School
26243	Owari no Seraph	Action, Military, Supernatural, Drama, Vampire, Shounen
14513	Magi: The Labyrinth of Magic	Action, Adventure, Fantasy, Magic, Shounen
4898	Kuroshitsuji	Action, Mystery, Comedy, Historical, Demons, Supernatural, Shounen
25777	Shingeki no Kyojin Season 2	Action, Military, Mystery, Super Power, Drama, Fantasy, Shounen

Figura 13: Recomendaciones para un usuario interesado en la acción, drama y romance

Para nuestro tercer usuario (**figura 14**), tenemos que sus gustos se centran en los géneros de la **acción, misterio y supernatural**. De las recomendaciones, es claro que se logró captar el género de acción, ya que casi todas pertenecen a este. Es interesante además ver como recomendó varios animes que mezclan acción con misterio, tales como *Shingeki no Kyojin* (2 de sus temporadas aparecen recomendadas), *Full Metal Alchemist* y *Baccano!*. Por último, todos estos animes son bien conocidos por tener una buena historia (están en muy buenas posiciones dentro del ranking de la plataforma), lo que respalda nuevamente la calidad de nuestro sistema.

User ID: 161872  
Previously Watched

anime_id	Name	Genres
3588	Soul Eater	Action, Fantasy, Comedy, Supernatural, Shounen
6746	Durarara!!	Action, Mystery, Supernatural
10163	C: The Money of Soul and Possibility Control	Action, Mystery, Super Power, Thriller
14131	Girls & Panzer	Action, Sports, Military, School
16049	Toaru Kagaku no Railgun S	Action, Sci-Fi, Super Power
29786	Shimoneta to Iu Gainen ga Sonzai Shinai Taikutsu na Sekai	Comedy, Ecchi, School
31757	Kizumonogatari II: Nekketsu-hen	Action, Mystery, Supernatural, Vampire
32867	Bungou Stray Dogs 2nd Season	Action, Mystery, Seinen, Super Power, Supernatural
32937	Kono Subarashii Sekai ni Shukufuku wo! 2	Adventure, Comedy, Parody, Supernatural, Magic, Fantasy
36028	Golden Kamuy	Action, Adventure, Historical, Seinen

Recommended

anime_id	Name	Genres
32182	Mob Psycho 100	Action, Slice of Life, Comedy, Supernatural
199	Sen to Chihiro no Kamikakushi	Adventure, Supernatural, Drama
11597	Nisemonogatari	Mystery, Comedy, Supernatural, Ecchi
25777	Shingeki no Kyojin Season 2	Action, Military, Mystery, Super Power, Drama, Fantasy, Shounen
121	Fullmetal Alchemist	Action, Adventure, Comedy, Drama, Fantasy, Magic, Military, Shounen
18679	Kill la Kill	Action, Comedy, Super Power, Ecchi, School
2251	Baccano!	Action, Comedy, Historical, Mystery, Supernatural
38524	Shingeki no Kyojin Season 3 Part 2	Action, Drama, Fantasy, Military, Mystery, Shounen, Super Power
36456	Boku no Hero Academia 3rd Season	Action, Comedy, Super Power, School, Shounen
24833	Ansatsu Kyoushitsu	Action, Comedy, School, Shounen

Figura 14: Recomendaciones para un usuario interesado en los géneros de acción, misterio y supernatural

Finalmente, podemos concluir que nuestro mejor modelo recomendador logra entregar resultados de gran calidad para los usuarios de la plataforma, aunque tiene espacio para mejorar en cuanto a la precisión de sus recomendaciones. Esto último se refiere a que en algunos casos las recomendaciones no tienen tanta relación con lo visto por el usuario anteriormente, aunque probablemente le gustarán de todas formas (por ejemplo al segundo usuario no la aparecieron tantas comedias recomendadas, siendo que son de sus preferidas).

## Referencias

- [1] Top Anime - Most Popular. (s. f.). MyAnimeList.Net. Recuperado 17 de septiembre de 2021, de <https://myanimelist.net/topanime.php?type=bypopularity>
- [2] Narapareddy, A. (2019, 13 octubre). Recommender system using Bayesian personalized ranking. Medium. <https://towardsdatascience.com/recommender-system-using-bayesian-personalized-ranking-d30e98bba0b9>
- [3] TensorFlow Hub. (s. f.). TensorFlow Hub. Recuperado 17 de septiembre de 2021, de <https://tfhub.dev/google/universal-sentence-encoder/1>
- [4] B. (2020, 19 octubre). Euclidean Distance vs Cosine Similarity. Baeldung on Computer Science. <https://www.baeldung.com/cs/euclidean-distance-vs-cosine-similarity>